Aaron M. Mueller

COORDONNÉES Center for Language & Speech Processing

Courriel: amueller@jhu.edu

Johns Hopkins University

Site web: aaronmueller.github.io Code: github.com/aaronmueller

3400 N. Charles St., Hackerman 319 Baltimore, MD 21218-2608 (É-U)

INTÉRÊTS DE RECHERCHE

• TALN multilingue

• Psycholinguistique informatique

• Traduction automatique

FORMATION Johns Hopkins University, Baltimore, MD, É-U

> Mai 2023 (attendu) Doctorant en informatique. Maîtrise en informatique. Mai 2020

GPA: 3.9/4.0.

Directeurs de thèse: Tal Linzen, Mark Dredze.

New York University, New York, NY, É-U

Chercheur visiteur, Center for Data Science. Août 2021 - mai 2023

Conseiller: Tal Linzen.

University of Kentucky, Lexington, KY, É-U

Baccalauréat en informatique (avec mention). Mai 2018 Baccalauréat en linguistique (avec mention). Mai 2018

GPA: 4.0/4.0. Summa cum laude.

Thèse: Neural Machine Translation for Canadian French.

EXPÉRIENCE Meta DE L'INDUSTRIE Stagiaire en recherche, AI Integrity Menlo Park, CA, É-U

Mai - septembre 2022

Manager: Kanika Narang

- Recherche en méta-apprentissage augmenté de récupération pour les systèmes de questions-réponses sur quelques exemples.

 Réalisation des F1 améliorés sur plusieurs tâches questions-réponses et classifications en utilisant moins de paramètres que les systèmes pré-entraînés de pointe.

Amazon Web Services (AWS)

Santa Clara, CA, É-U

Stagiaire en recherche appliqué, Lex

Manager: Saab Mansour

Mai - août 2021

- Recherche en améliorer les systèmes de dialogue orientés tâche.
- Réalisation des précisions de pointe sur la classification d'intention sur quelques exemples (>30% sur 1 exemple) et une publication à l'ACL.

Raytheon BBN Technologies, Cambridge, MA, É-U

Analytics & Machine Intelligence

Stagiaire en recherche, Analytics & Machine Intelligence

Mai - août 2019

Superviseurs: Roger Bock, Ilana Heintz

- Implementation des systèmes de traduction automatique convolutionelle qui rivalise notre système seq2seq précédent, mais avec l'apprentissage 20% plus rapide et l'inference 50% plus rapide.
- Recherche en alignement des mots et annotation sémantique multilingue à faibles ressources en russe et ukrainien.

PUBLICATIONS COMPTES RENDUS DE CONFÉRENCES

- 1. Aaron Mueller, Robert Frank, Tal Linzen, Luheng Wang, Sebastian Schuster. "Coloring the Blank Slate: Pre-training Imparts a Hierarchical Inductive Bias to Sequence-to-sequence Models." Findings of the Association for Computational Linguistics (ACL), 2022.
- 2. Aaron Mueller, Jason Krone, Salvatore Romeo, Saab Mansour, Elman Mansimov, Yi Zhang, Dan Roth. "Label Semantic Aware Pre-training for Few-shot Text Classification." Proceedings of the Association for Computational Linguistics (ACL), 2022.

- 3. **Aaron Mueller**, Yu Xia, Tal Linzen. "Causal Analysis of Syntactic Agreement Neurons in Multilingual Language Models." *Proceedings of the Conference on Computational Natural Language Learning (CoNLL)*, 2022.
- 4. **Aaron Mueller**, Mark Dredze. "Fine-tuning Encoders for Improved Monolingual and Zero-shot Polylingual Neural Topic Modeling." *Proceedings of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2021.
- 5. **Aaron Mueller**, Zach Wood-Doughty, Silvio Amir, Mark Dredze, Alicia L. Nobles. "Demographic Representation and Collective Storytelling in the Me Too Twitter Hashtag Activism Movement." *Proceedings of the Association for Computing Machinery (ACM) on Human-Computer Interaction (HCI), vol. CSCW1*, 2021.
- 6. Matthew Finlayson*, **Aaron Mueller***, Sebastian Gehrmann, Stuart Shieber, Tal Linzen, Yonatan Belinkov. "Causal Analysis of Syntactic Agreement Mechanisms in Neural Language Models." *Proceedings of the Association for Computational Linguistics (ACL)*, 2021. [*Contribution égale]
- 7. Alexandra DeLucia*, **Aaron Mueller***, Xiang Lisa Li, João Sedoc. "Decoding Methods for Neural Narrative Generation." *Proceedings of the Workshop on Generation Evaluation and Metrics (GEM) at Association for Computational Linguistics (ACL)*, 2021. [*Contribution égale]
- 8. **Aaron Mueller**, Garrett Nicolai, Panayiota Petrou-Zeniou, Natalia Talmina, Tal Linzen. "Crosslinguistic Syntactic Evaluation of Word Prediction Models." *Proceedings of the Association for Computational Linguistics (ACL)*, 2020.
- 9. **Aaron Mueller**, Garrett Nicolai, Arya D. McCarthy, Dylan Lewis, Winston Wu, David Yarowsky. "An Analysis of Massively Multilingual Neural Machine Translation for Low-Resource Languages." *Proceedings of the Language Resources and Evaluation Conference (LREC)*, 2020.
- Arya D. McCarthy, Rachel Wicks, Dylan Lewis, Aaron Mueller, Winston Wu, Oliver Adams, Garrett Nicolai, Matt Post, David Yarowsky. "The Johns Hopkins University Bible Corpus: 1600+ Tongues for Typological Exploration." *Proceedings of the Language Resources and Evaluation Conference (LREC)*, 2020.
- 11. Garrett Nicolai, Dylan Lewis, Arya D. McCarthy, **Aaron Mueller**, Winston Wu, David Yarowsky. "Fine-grained Morphosyntactic Analysis and Generation Tools for More Than One Thousand Languages." *Proceedings of the Language Resources and Evaluation Conference (LREC)*, 2020.
- 12. Marten van Schijndel, **Aaron Mueller**, Tal Linzen. "Quantity Doesn't Buy Quality Syntax with Neural Language Models." *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019.
- 13. Arya D. McCarthy, Winston Wu, **Aaron Mueller**, Bill Watson, David Yarowsky. "Modeling Color Terminology Across Thousands of Languages." *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2019.
- 14. Aaron Mueller*, Yash Kumar Lal*. "Sentence-Level Adaptation for Low-Resource Neural Machine Translation." Proceedings of the Workshop on Technologies for Machine Translation of Low-Resource Languages (LoResMT) at Machine Translation Summit (MTSummit), 2019. [*Contribution égale]

Non-revues et autres

- 15. Julian Michael, Ari Holtzman, Alicia Parrish, **Aaron Mueller**, Alex Wang, Angelica Chen, Divyam Madaan, Nikita Nangia, Richard Yuanzhe Pang, Jason Phang, Samuel R. Bowman. "What do NLP Researchers Believe? Results of the NLP Community Metasurvey." *Prépublication arXiv*, 2022.
- 16. **Aaron Mueller**, Mark Richard Lauersdorf, Kevin McGowan, Ramakanth Kavuluru. "Neural Machine Translation for Canadian French." *Thèse de premier cycle*, 2018.

Présentations invitées

Aaron Mueller. "What Generalizations do Sequence-to-sequence Models Learn from Multilingual Text? Insights from Translation and Syntactic Transformations." Au Conseil national de recherches Canada (Ottawa, ON, CA). 4 mars 2022. Présentation virtuelle.

Aaron Mueller. "Syntactic Agreement in Neural Language Models: How Well and Where Do They Perform Subject-Verb Agreement?" Au Mila – Institut de recherche, groupe Language & Understanding (Montréal, QC, CA). 22 mars 2021. Présentation virtuelle.

Aaron Mueller*, Sebastian Gehrmann*. "Causal Mediation Analysis for Analyzing Neural Networks." À Google, groupe Fairness & Interpretability (New York, NY, É-U). 17 mars 2021. Présentation virtuelle. [*Contribution égale]

Aaron Mueller. "Causal Analysis of Syntactic Agreement Mechanisms in Neural Language Mod-

els." À la Johns Hopkins University, séminaire de Center for Language & Speech Processing (Baltimore, MD, É-U). 12 février 2021. Virtual talk.

EXPÉRIENCE

Johns Hopkins University, Baltimore, MD, É-U

ACADÉMIQUE

Assistant de recherche, Center for Language & Speech Processing

Août 2018 - présent

EN RECHERCHE Superviseur: Mark Dredze, David Yarowsky

- Recherche en traduction automatique neuronale, génération du langage naturel, et le TALN multilingue.

Assistant de recherche, Center for Language & Speech Processing

Mai - août 2016

Superviseur: David Yarowsky

- Recherche en traduction automatique statistique pour les langues à faibles ressources.
- Mettre en œuvre un modèle de traduction anglais-ouïghour basé sur les lemmes, un générateur morphologique pour le tatar de Crimée, et des analyseurs syntaxiques pour soutirer les tables de traduction des éditions étrangères de Wiktionnaire.

New York University, New York, NY, É-U

Chercheur visiteur. Center for Data Science

Août 2021 - présent Superviseur: Tal Linzen

- Création des probes linguistiques pour comprendre la connaissance syntaxique et morphologique des modèles pré-entraînés.

University of Massachusetts Amherst, Amherst, MA, É-U Statistical Social Language Analysis Lab

Assistant de recherche

Mai - août 2017

Superviseur: Brendan O'Connor

- Recherche en extraction des entités et évènements des textes.
- Intégrer les systèmes d'extraction des relations des entités dans un modèle préexistant au niveau des phrases complètes. Intégrer l'information au niveau du document (p. ex., les coréférences de noms).

BOURSES ET PRIX

Boursier de recherche de la National Science Foundation

2018 - 2023

Boursier Gaines

2016 - 2018

Bourse de recherche de deux ans. Elle nécessite l'achèvement d'un projet de jury, un thèse et un cours séminaire en sciences humaines. (\$5 000 USD)

Boursier Patterson 2014 - 2018

Décernée aux étudiants à l'Université du Kentucky qui ont gagné le Bourse national du mérite. (\$80 000+ USD)

Boursier Raymond F. Betts

Décernée à un étudiant par an pour aider ses travaux de thèse. Utilisé les fonds pour étudier le français québécois à Montréal et à Québec pendant l'hiver de 2017–2018. (\$2 500 USD)

Bourse Goldwater (Mention honorable)

2017

Phi Beta Kappa Prix de recherche en linguistique

2017 2016

Décernée à un étudiant pour faciliter un projet de recherche d'une année en linguistique. Utilisé les fonds pour un projet de sociolinguistique quantitative examinant les glissements sémantiques des mots sexospécifiques dans les médias américains sur 200 ans. (\$500 USD)

EXPÉRIENCE EN Johns Hopkins University, Baltimore, MD, É-U

ENSEIGNEMENT Assistant

- Machine Learning: AI System Design and Development, Mathias Unberath. Printemps 2020.

MENTORAT

Étudiants de maîtrise

Yash Kumar Lal (JHU. Maintenant doctorant à la Stony Brook University.)

2018-2019

Chercheurs de premier cycle

Yu Xia (NYU. Maintenant étudiant de maîtrise à la New York University.)

2021-2022

Matthew Finlayson (Harvard. Maintenant chercheur prédoctoral à l'Allen Institute for AI.) 2020-2021

COMPÉTENCES Programmation:

INFORMATIQUES - Langages (expert): Python, C++, HTML, CSS, Javascript, Bash.

- Toolkits d'apprentissage automatique: PyTorch (dont huggingface, fairseq, sockeye), Keras, TensorFlow.
- Contrôle de version: DVCS (Git, Bitbucket).

Outils linguistiques:

Praat, AntConc, QGIS, Audacity.

SERVICE Examinateur principal: ACL (2022, 2020), EMNLP (2022, 2019), NAACL (2021), CoNLL (2022),

COLING (2020).

Examinateur secondaire: TACL (2022).

LANGUES Français (B2, canadien), anglais (langue maternelle).